David O'Neil

Engenheiro de IA · LLM / NLP · Líder Técnico

Goiânia, GO · davidoneil33@gmail.com · +55 62 98135-8075
linkedin.com/in/davidoneilai · github.com/davidoneilai · huggingface.co/davidoneil · davidoneilai.github.io/davidoneil

Engenheiro de NLP e LLMs com mais de 4 anos construindo e treinando modelos de linguagem. Lidero o pós-treino dos modelos próprios da CEMIG em GPUs NVIDIA B200 e H100 (SFT, LoRA, DPO e GRPO) e o time de pesquisa em NLP do Digital Humans II. Tenho código aceito nos repositórios oficiais da NVIDIA (NeMo, Megatron e Nemotron) e artigos publicados no AACL, ICLR, ICML e ACL. Em produção, implantei sistemas de busca híbrida, Graph RAG, agentes e MLOps no TCE-GO e no TCM-GO, com R$ 1,8 milhão em economia reportada.

EXPERIÊNCIA

Líder Técnico · Treino de Modelos
CEMIG · CEIA / UFG

- Responsável pelo pós-treino dos LLMs próprios da CEMIG para o português brasileiro e o setor elétrico, definindo geração de dados sintéticos por destilação, curadoria de bases internas e critérios de avaliação.
- Execução de SFT, LoRA, full fine-tuning, DPO e GRPO em Qwen-3/3.5, Gemma-4, LLaMA 3.1/3.2 e Tucano em clusters NVIDIA Blackwell B200, DGX H100 e A100 com NeMo, Megatron, Axolotl e Unsloth.
- Construção de pipelines de dados com deduplicação semântica, filtros heurísticos, pares de preferência e filtragem de recompensa para reduzir alucinações e manter saídas estruturadas.
- Avaliação em benchmarks públicos (MT-Bench e Arena-Hard) combinada a testes próprios de precisão factual sobre normas da ANEEL.
- Autor de commits e pull requests aceitos nos repositórios oficiais da NVIDIA (NeMo, Megatron e Nemotron).

NLP Team Lead · Pesquisa
Digital Humans II · AKCIT / EMBRAPII

- Liderança técnica da equipe de NLP, definindo objetivos de treino, geração de datasets e avaliações de consistência de persona.
- Pesquisa em Sparse Autoencoders, steering de ativações, Steering-Conditioned LoRA, alinhamento de persona e memória episódica, resultando em quatro artigos aceitos e um em revisão.

Tech Lead & NLP Engineer
TRON · CEIA

- Liderança técnica do copilot de suporte da TRON: Graph RAG com agentes de reescrita e rerank integrado a um ERP legado em Delphi para executar ações direto na aplicação, além de extensão web para os atendentes.
- Fine-tuning do encoder BGE-M3 com triplet loss e mineração de hard negatives no vocabulário do sistema.

NLP Engineer
TCM-GO · Tribunal de Contas dos Municípios de Goiás

- Desenvolvimento e colocação em produção do sistema de chat e análise documental do tribunal, com economia operacional reportada de R$ 1,8 milhão.
- Estruturação de dados em arquitetura Medallion, MLOps na infraestrutura local, RAG jurídico e fine-tuning de modelos para redigir seções de peças jurídicas.

NLP Engineer
TCE-GO · Tribunal de Contas do Estado de Goiás

- Busca híbrida (BM25 + embeddings) sobre acórdãos e processos, usando extração de metadados via regex para filtrar consultas exatas.
- Fine-tuning de encoders (E5, BGE-M3 e Qwen Embedding) com perda contrastiva e triplet loss, Graph RAG com agentes e deploy de serviços de chat, sumarização e QA.

Fundador · Produtos de IA
Pergunt.ai (CEO & Co-Founder, 2023) · Validoo · PUMP

- Pergunt.ai: plataforma de estudo que gerava questões inéditas de concursos com IA e ajustava recomendações pelo desempenho do aluno.
- Validoo: SaaS de conformidade regulatória para transporte rodoviário. PUMP: app iOS de fotografia com modelos Core ML on-device e IA generativa.

FORMAÇÃO

Bacharelado em Inteligência Artificial 2023 a 2027
Universidade Federal de Goiás (UFG)
Primeira graduação em Inteligência Artificial da América Latina. Em andamento.

PUBLICAÇÕES

Episodic Memory from Compression Boundaries in Latent Representation Space
AACL-IJCNLP 2026 (Main Conference) · ICLR 2026 MemAgents Workshop (Oral)

Steering-Conditioned LoRA via Sparse Autoencoders
ICML 2026 · CoLoRAI Workshop (Pôster)

AKCIT-UFG at SemEval-2026 Task 8: Structured Chunking and Optimized Query Reformulation for Efficient Multi-Turn Retrieval
ACL 2026 · SemEval Workshop

ECHO: A Latent Register Axis Composes with Prompting for Persona-Conditioned Generation
ACL ARR 2026 (agosto) · EACL · em revisão

COMPETÊNCIAS TÉCNICAS

Linguagens / infra: Python · Go · C / C++ · Java · R · JavaScript / TypeScript · PyTorch · CUDA · Docker · GCP
Open source: 13 modelos no Hugging Face · BGE-M3 afinado para PT (+ ONNX) · Embeddings Gemma (TCE-GO) · SAEs em LLaMA 3.2
Pós-treino de LLM: SFT · LoRA / full FT · DPO / GRPO · Dados sintéticos · Avaliação de LLMs · NeMo / Megatron · Axolotl / Unsloth
RAG, agentes e produção: Graph RAG · RAG híbrido · Orquestração de agentes · Embeddings (E5, BGE-M3) · Medallion · MLOps