

DAVID O'NEIL

NLP Researcher | LLM Specialist | AI Technical Lead

Goiânia, GO, Brasil | davidoneil33@gmail.com | +55 62 98135-8075 | [linkedin.com/in/davidoneilai](https://www.linkedin.com/in/davidoneilai) | 21 anos

Pesquisador e engenheiro de NLP com experiência prática em pós-treino de Grandes Modelos de Linguagem (LLMs), liderança técnica de equipes de IA e arquitetura de sistemas complexos de Processamento de Linguagem Natural. Atua como líder técnico no projeto de LLMs da CEMIG (CEIA/UFG) e como LLM Team Lead no projeto Digital Humans II (AKCIT/EMBRAPII). **Contribuidor oficial de repositórios da NVIDIA (Nemotron, Megatron, Nemo)**. Coautor de artigos publicados no **ICLR 2026 (MemAgents Workshop - Oral)**, **ICML 2026 (CoLoRAI - Pôster)** e **ACL 2026 (SemEval Workshop)**. Especialista em adaptação de modelos para o português brasileiro, fine-tuning avançado (LoRA, Full, GRPO, DPO), arquiteturas de Graph RAG, recuperação híbrida e desenvolvimento de agentes de IA integrados a ambientes legados e corporativos.

EXPERIÊNCIA PROFISSIONAL

LLM Team Lead | Digital Humans II

Centro de Competência EMBRAPII em Tecnologias Imersivas - AKCIT

- Liderança do treinamento e melhoria contínua de modelos de linguagem (LLMs), com foco em alinhamento de personas para diferentes contextos, incluindo interações educacionais e fluxos de trabalho orientados à pesquisa para suporte a publicações acadêmicas.
- Definição de objetivos de treinamento, curadoria e geração de datasets, execução de ciclos de treinamento e aplicação de estratégias de alinhamento avançadas (além do SFT tradicional) quando necessário.
- Design e aplicação de avaliações e benchmarks rigorosos para garantir comportamento consistente e de alta qualidade, mantendo o estrito alinhamento com a persona proposta.
- Contribuição direta para as publicações científicas do projeto, refletindo o foco da equipe em alinhamento de LLMs, memória, fine-tuning eficiente e adaptação para aplicações do mundo real.

NLP Researcher — CEMIG (Companhia Energética de Minas Gerais) Centro de Excelência em Inteligência Artificial (CEIA), Líder técnico responsável pelos esforços de Supervised Fine-Tuning (SFT) e pós-treino no projeto de pesquisa de LLMs da CEMIG, focado na adaptação e melhoria de modelos para o português brasileiro e casos de uso empresarial no setor elétrico.

Líder técnico responsável pelos esforços de Supervised Fine-Tuning (SFT) e pós-treino no projeto de pesquisa de LLMs da CEMIG, focado na adaptação e melhoria de modelos para o português brasileiro e casos de uso empresarial no setor elétrico.

- **Pós-treino e Fine-Tuning:** Execução de pipelines de SFT e alinhamento utilizando diversas abordagens, incluindo LoRA, Full Fine-Tuning e GRPO (Group Relative Policy Optimization).

- **Otimização de Preferência (DPO/GRPO):** Criação e curadoria de datasets de preferência (comparações pareadas) para alinhamento via DPO e GRPO, implementando pipelines de anotação e filtragem de recompensa para reduzir alucinações e melhorar a aderência a formatos de saída estruturados.
- **Ecossistema NVIDIA e Ferramentas Ágeis:** Utilização avançada de frameworks como Nemotron, Megatron e Nemo, com **contribuições oficiais aceitas no repositório open-source da NVIDIA**. Experiência prática na aceleração de pipelines com **Axolotl** e **Unsloth**.
- **Engenharia e Curadoria de Dados:** Implementação de pipelines robustos de preparação de dados, incluindo deduplicação semântica, filtragem de qualidade heurística e geração de dados sintéticos supervisionados (via destilação de modelos maiores) para cenários de *long-context* e *edge cases*, garantindo consistência factual no domínio do setor elétrico.
- **Definição da estratégia de SFT:** Planejamento e execução da estratégia de fine-tuning supervisionado para adaptar LLMs ao contexto corporativo e operacional da CEMIG, incluindo normas reguladoras do setor elétrico (ANEEL) e linguagem técnica específica.
- **Avaliação Rigorosa de Modelos:** Desenvolvimento e aplicação de benchmarks customizados e adaptação de suites padrão (ex: MT-Bench, Arena-Hard) e métricas específicas de domínio (ex: exatidão factual em normas da ANEEL) para avaliar qualidade linguística, redução de alucinações e alinhamento com o contexto empresarial brasileiro.
- **Coordenação de experimentos:** Gestão de pipelines de treinamento em infraestrutura de alta performance (supercomputadores NVIDIA H100/B200), incluindo ajuste de hiperparâmetros, monitoramento de métricas de convergência e otimização de recursos computacionais.

Tech Lead & NLP Engineer — Centro de Excelência em Inteligência Artificial, TRON

Coordenador da equipe de desenvolvimento no projeto CEIA em parceria com a TRON, focado em soluções de NLP para construção de um ambiente de copilot integrado a plataformas de atendimento ao cliente.

- **Arquitetura Graph RAG e Multi-Agentes:** Implementação de um ambiente conversacional baseado em Graph RAG, orquestrando múltiplos nós com agentes especializados (ex: Query Rewrite, Rerank) para maximizar a precisão e o contexto das respostas.
- **Integração Agêntica em Ambiente Legado:** Desenvolvimento e implementação de um copilot dentro de um ambiente legado em Delphi, capacitando o agente de IA a executar ações diretas e automatizadas dentro da aplicação com base nos comandos do usuário.
- **Ferramenta de Apoio ao Atendente:** Criação de uma solução de extensão web que permite aos atendentes da TRON interagir livremente com a pipeline de IA para solucionar dúvidas internas, garantindo respostas de maior qualidade e velocidade ao usuário final.
- **SFT em Modelos Encoder:** Fine-tuning supervisionado do modelo encoder BGE-M3 utilizando triplet loss. Desenvolvimento de um dataset robusto e aplicação de técnicas de hard negative mining para aprimorar drasticamente a recuperação de contexto semântico.

NLP Engineer — Tribunal de Contas do Estado de Goiás (TCE-GO)

Desenvolvimento e implantação de soluções práticas e robustas de NLP para o ambiente jurídico e do setor público, lidando com datasets extensos e complexos.

- **Pipeline de RAG Híbrida e Complexa:** Desenvolvimento de uma arquitetura de recuperação que combina busca lexical e semântica (hybrid retriever), essencial para lidar com documentos jurídicos complementares que exigiam contexto cruzado.

- **Otimização de Queries com Regex e Metadados:** Implementação de regras de Regex para detecção de metadados específicos nas queries dos usuários, permitindo buscas exatas e diretas no banco de dados em cenários onde a busca puramente semântica era insuficiente ou imprecisa.
- **Avaliação e Seleção de Modelos:** Execução de múltiplos ciclos de fine-tuning em diferentes arquiteturas, estabelecendo critérios rigorosos de avaliação para selecionar e validar o modelo ótimo para o ambiente de produção.
- **Soluções de NLP em Produção:** Construção e manutenção de pipelines que suportam chatbots para extração dinâmica de informações, sumarização automática de documentos jurídicos e sistemas de resposta a consultas (QA), com participação ativa no deploy e integração no ambiente operacional.

NLP Engineer — Tribunal de Contas dos Municípios de Goiás (TCM-GO)

- Desenvolvimento e implantação de aplicação de NLP voltada para chat, otimizando comunicação e extração de informações, resultando em **economia de R\$ 1,8 milhão**.
- Implementação de arquitetura RAG (Retrieval-Augmented Generation) para geração e análise de documentos jurídicos.
- Fine-tuning customizado de modelos pré-existentes para geração de partes específicas de documentos jurídicos, adaptados às necessidades do ambiente legal.
- Trabalho com MLOps, garantindo integração e deploy eficiente de modelos de IA na infraestrutura do TCM-GO..

CEO & Co-Founder — Pergunt.ai 2023

- Liderança de startup no setor educacional, especializada em IA generativa para criação de questões inéditas e personalizadas para concursos públicos.
- Desenvolvimento de sistema de recomendação baseado em IA, alinhando conteúdos relevantes ao perfil dos usuários e acompanhando o desempenho dos alunos com insights detalhados.

FORMAÇÃO ACADÊMICA

Bacharelado em Inteligência Artificial Universidade Federal de Goiás (UFG) — 2023 — 2027 (Cursando)

- Primeiro curso de Inteligência Artificial da América Latina.

PUBLICAÇÕES CIENTÍFICAS

- **Episodic Memory from Compression Boundaries in Latent Representation Space — *ICLR 2026 MemAgents Workshop* (Apresentação Oral).** Pesquisa focada em memória episódica, limites de compressão e representação latente em agentes de LLM.
- **Steering-Conditioned LoRA via Sparse Autoencoders — *2nd Workshop on Connecting Low-rank Representations in AI (CoLoRAI), ICML 2026* (Pôster).** Pesquisa que conecta técnicas de pós-treino e adaptação eficiente de modelos (LoRA) com sparse autoencoders para *model steering* condicionado.
- **AKCIT-UFG at SemEval-2026 Task 8: Structured Chunking and Optimized Query Reformulation for Efficient Multi-Turn Retrieval — *ACL 2026 Workshop (SemEval)*.** Desenvolvimento de técnicas avançadas de chunking estruturado e reformulação otimizada de queries para maximizar a eficiência e precisão da recuperação de informação em cenários de diálogo multi-turno (Multi-Turn Retrieval).