David O'Neil

NLP / LLM 工程师 · 技术负责人

巴西戈亚尼亚 · davidoneil33@gmail.com · +55 62 98135-8075 · linkedin.com/in/davidoneilai · github.com/davidoneilai

NLP/LLM 工程师，4+ 年经验。CEMIG（CEIA/UFG）自有模型训练技术负责人，Digital Humans II（AKCIT/EMBRAPII）NLP Team Lead。官方 NVIDIA 仓库已接受贡献（NeMo、Megatron、Nemotron）。论文见于 ICLR、ICML、ACL、AACL。在 TCE-GO 与 TCM-GO 交付生产 NLP：混合 RAG、Graph RAG、MLOps；TCM-GO 据报节省 R$180 万。

经历

NLP Team Lead · 研究
Digital Humans II — AKCIT / EMBRAPII

- 领导 NLP 团队（有直接下属）。任务是基础研究与发表——可解释性、人设对齐、情景记忆——不是产品工程。
- 研究方向：Sparse Autoencoders、steering、Steering-Conditioned LoRA、人设对齐、情景记忆与推理加速。
- 四篇已接收（AACL-IJCNLP 2026 主会、ICLR MemAgents 口头、ICML CoLoRAI、ACL SemEval）；ECHO 审稿中，目标 EACL。

技术负责人 · 模型训练
CEMIG — CEIA / UFG

- CEMIG 自有 LLM 训练技术负责人：决定合成数据策略、内部数据用法，以及评测（公开基准 vs. 领域标准，如 ANEEL 事实正确性）。
- 在 NVIDIA Blackwell B200、DGX H100、A100 上对 Qwen-3/3.5、Gemma-4、LLaMA 3.1/3.2、Tucano 执行 SFT、LoRA、全量微调、DPO、GRPO（NeMo、Megatron、Axolotl、Unsloth）。
- 官方 NVIDIA 仓库已接受 commit/PR（NeMo / Megatron / Nemotron）。

Tech Lead & NLP Engineer
TRON — CEIA

- CEIA×TRON 副驾驶技术负责人：带专用智能体（查询改写、重排）的 Graph RAG，可在 Delphi 遗留应用中执行动作，另有客服侧 Web 扩展。
- 用 triplet loss 与难负例挖掘对 BGE-M3 做监督微调，提升检索质量。

NLP Engineer
TCE-GO — 戈亚斯州审计法院

- 面向互补法律文书的混合 RAG（词汇 + 稠密）；语义检索不足时用正则/元数据路由。
- 对 E5、BGE-M3、Qwen Embedding 做对比/triplet SFT；Graph RAG 与智能体编排；生产聊天、摘要与问答，含部署。

NLP Engineer
TCM-GO — 戈亚斯州市审计法院

- NLP 聊天产品据报节省 R$180 万；法律 RAG 与文书段落微调。
- Medallion 数据架构、机构基础设施上的 MLOps、编码器训练/评测，以及 TCM 库上的智能体流水线。

CEO & 联合创始人 2023
Pergunt.ai

- 教育 GenAI：原创公考题，并对学情做推荐。

教育

人工智能学士 2023 — 2027
戈亚斯联邦大学（UFG）
拉丁美洲首个人工智能本科项目。在读。

论文

Episodic Memory from Compression Boundaries in Latent Representation Space
AACL-IJCNLP 2026 Main

Episodic Memory from Compression Boundaries in Latent Representation Space
ICLR 2026 · MemAgents Workshop（口头）

Steering-Conditioned LoRA via Sparse Autoencoders
ICML 2026 · CoLoRAI Workshop（海报）

AKCIT-UFG at SemEval-2026 Task 8: Structured Chunking and Optimized Query Reformulation for Efficient Multi-Turn Retrieval
ACL 2026 · SemEval Workshop

ECHO: A Latent Register Axis Composes with Prompting for Persona-Conditioned Generation
ACL ARR 2026 August · EACL · 审稿中

技能

LLM 后训练: SFT · LoRA / full FT · DPO / GRPO · 合成数据 · 公开 + 自建评测 · Qwen-3/3.5 · Gemma-4 · LLaMA 3.1/3.2 · Tucano · Axolotl / Unsloth
研究 / 可解释性: Sparse Autoencoders · Steering · Steering-Conditioned LoRA · 人设对齐 · 情景记忆 · 推理加速
检索 / 生产: E5 / BGE-M3 / Qwen Embedding · Triplet / 对比 · Graph RAG · 智能体编排 · BM25 + 元数据 · Medallion · MLOps
NVIDIA / 算力: Blackwell B200 · DGX H100 · A100 · NeMo · Megatron · Nemotron