

David O'Neil

NLP / LLM 工程师 · 技术负责人

巴西戈亚尼亚 · davidoneil33@gmail.com · +55 62 98135-8075 · linkedin.com/in/davidoneilai · github.com/davidoneilai

NLP/LLM 工程师, 4+ 年经验。CEMIG (CEIA/UFG) 自有模型训练技术负责人, Digital Humans II (AKCIT/EMBRAPPII) NLP Team Lead。官方 NVIDIA 仓库已接受贡献 (NeMo、Megatron、Nemotron)。论文见于 ICLR、ICML、ACL。在 TCE-GO 与 TCM-GO 交付生产 NLP: 混合 RAG、Graph RAG、MLOps; TCM-GO 据报节省 R\$180 万。

经历

NLP Team Lead · 研究

Digital Humans II — AKCIT / EMBRAPPII

- 领导 NLP 团队 (有直接下属)。任务是基础研究与发表——可解释性、人设对齐、情景记忆——不是产品工程。
- 研究方向: Sparse Autoencoders、steering、Steering-Conditioned LoRA、人设对齐、情景记忆与推理加速。
- 三篇已接收研讨会论文 (ICLR MemAgents 口头、ICML CoLoRAI、ACL SemEval); 两篇顶会审稿中。

技术负责人 · 模型训练

CEMIG — CEIA / UFG

- CEMIG 自有 LLM 训练技术负责人: 决定合成数据策略、内部数据用法, 以及评测 (公开基准 vs. 领域标准, 如 ANEEL 事实正确性)。
- 在 NVIDIA Blackwell B200、DGX H100、A100 上对 Qwen-3/3.5、Gemma-4、LLaMA 3.1/3.2、Tucano 执行 SFT、LoRA、全量微调、DPO、GRPO (NeMo、Megatron、Axolotl、Unsloth)。
- 官方 NVIDIA 仓库已接受 commit/PR (NeMo / Megatron / Nemotron)。

Tech Lead & NLP Engineer

TRON — CEIA

- CEIAxTRON 副驾驶技术负责人: 带专用智能体 (查询改写、重排) 的 Graph RAG, 可在 Delphi 遗留应用中执行动作, 另有客服侧 Web 扩展。
- 用 triplet loss 与难负例挖掘对 BGE-M3 做监督微调, 提升检索质量。

NLP Engineer

TCE-GO — 戈亚斯州审计法院

- 面向互补法律文书的混合 RAG (词汇 + 稠密); 语义检索不足时用正则/元数据路由。
- 对 E5、BGE-M3、Qwen Embedding 做对比/triplet SFT; Graph RAG 与智能体编排; 生产聊天、摘要与问答, 含部署。

NLP Engineer

TCM-GO — 戈亚斯州市审计法院

- NLP 聊天产品据报节省 R\$180 万; 法律 RAG 与文书段落微调。
- Medallion 数据架构、机构基础设施上的 MLOps、编码器训练/评测, 以及 TCM 库上的智能体流水线。

CEO & 联合创始人

Pergunt.ai

- 教育 GenAI: 原创公考题, 并对学情做推荐。

2023

教育

人工智能学士

戈亚斯联邦大学 (UFG)

拉丁美洲首个人工智能本科项目。在读。

2023 — 2027

论文

Episodic Memory from Compression Boundaries in Latent Representation Space

ICLR 2026 · MemAgents Workshop (口头)

Steering-Conditioned LoRA via Sparse Autoencoders

ICML 2026 · CoLoRAI Workshop (海报)

AKCIT-UFG at SemEval-2026 Task 8: Structured Chunking and Optimized Query Reformulation for Efficient Multi-Turn Retrieval

ACL 2026 · SemEval Workshop

技能

LLM 后训练: SFT · LoRA / full FT · DPO / GRPO · 合成数据 · 公开 + 自建评测 · Qwen-3/3.5 · Gemma-4 · LLaMA 3.1/3.2 · Tucano · Axolotl / Unsloth

研究 / 可解释性: Sparse Autoencoders · Steering · Steering-Conditioned LoRA · 人设对齐 · 情景记忆 · 推理加速

检索 / 生产: E5 / BGE-M3 / Qwen Embedding · Triplet / 对比 · Graph RAG · 智能体编排 · BM25 + 元数据 · Medallion · MLOps

NVIDIA / 算力: Blackwell B200 · DGX H100 · A100 · NeMo · Megatron · Nemotron